

COMPARAÇÃO DA EFICIÊNCIA DE CNNs NA CLASSIFICAÇÃO DE DOENÇAS EM PLANTAS

1

Abstract. *This study investigates the effectiveness of different Convolutional Neural Network (CNN) architectures for plant disease classification using the PlantVillage dataset. The evaluated models include a Fully Connected network, ResNet50, and a hybrid CNN-LSTM architecture. Automated plant disease detection is a key component of precision agriculture, contributing to reduced crop losses and production costs. While traditionally performed by specialists, the adoption of artificial intelligence-based solutions can provide efficient support for decision-making in the field. The study describes the image preprocessing steps, including resizing to 224x224 pixels, normalization, dataset splitting into training, validation, and testing sets, and the application of data augmentation techniques. The models were evaluated using accuracy, precision, recall, F1-score, and confusion matrix. The results enable the identification of the most efficient architecture in terms of performance and computational feasibility for the development of automated agricultural monitoring systems. **keywords:** Artificial Neural Networks, Disease Classification, Deep Learning.*

Abstract. *Este estudo apresenta a implementação e comparação da eficiência de diferentes arquiteturas de Redes Neurais Convolucionais (CNNs), especificamente uma rede Densa (Fully Connected), ResNet50 e uma combinação de LSTM com CNN, na tarefa de classificação de doenças em plantas utilizando o conjunto de dados PlantVillage. A detecção automatizada de doenças em plantas é essencial para a agricultura moderna, assegurando a redução das perdas e dos custos de produção. A detecção e classificação de doenças são feitas por profissionais qualificados, entretanto, a incorporação de novas tecnologias pode oferecer suporte adicional a esses profissionais. A inteligência artificial, presente no dia a dia, pode ser integrada como solução baseada em IA para apoiar esses profissionais na tomada de decisão. O uso de Redes Neurais Artificiais Convolucionais, as conhecidas CNNs, passa a ser fundamental, com alta precisão. O trabalho detalha as etapas de pré-processamento de dados, incluindo redimensionamento para 224x224 pixels, normalização, divisão em conjuntos de treino, validação e teste, e aplicação de técnicas de aumento de dados. Os modelos foram treinados e avaliados utilizando métricas como acurácia, precisão, recall, F1-score e matriz de confusão. Os resultados práticos da implementação permitem identificar a arquitetura mais adequada em termos de desempenho e eficiência computacional para o desenvolvimento de sistemas automatizados de monitoramento agrícola. **Palavras-chave:** Redes Neurais Artificiais, Classificação de Doenças, Aprendizado Profundo.*

1. Introdução

A agricultura sempre enfrenta desafios para garantir a segurança alimentar, são diversas ameaças, que são deste intemperes do clima quando ameaças de pragas e doenças. Essas ocorrências podem levar a perdas significativas na produção agrícola, impactando diretamente a economia e a subsistência de comunidades. Segundo [Tessele et al. 2024], o uso de redes neurais artificiais pode otimizar a tomada de decisões no campo, contribuindo para identificar o momento ideal de manejo, como a dessecação da soja, com maior precisão e menor subjetividade. Métodos tradicionais de identificação de doenças, geralmente realizados por especialistas, por vezes são lentas e caras e suscetíveis a erros, especialmente em grandes extensões de cultivo. A necessidade de soluções mais rápidas, precisas e escaláveis impulsiona a busca por tecnologias inovadoras envolvendo a inteligência artificial (IA).

A IA atualmente é ferramenta presente no cotidiano das pessoas [Garcia 2020], e na agricultura vem se fortalecendo e é crescente o uso da tecnologia baseado em IA em todas as fases do cultivo [Vicari 2021]. A utilização da inteligência artificial no processo de tomada de decisões torna-se cada vez mais relevante, sendo necessário considerar aspectos de accountability e transparência [Pinto 2020]. Dentro do grande guarda-chuva que é a IA, o estudo aborda o uso das Redes Neurais Convolucionais (CNNs) como uma ferramenta poderosa e transformadora. As CNNs, uma subclasse do aprendizado profundo, são particularmente eficazes para tarefas de visão computacional, como reconhecimento e classificação de imagens [Simeón 2008]. Sua capacidade de aprender automaticamente características hierárquicas a partir dos dados de entrada, eliminando a necessidade de engenharia manual de atributos, as torna ideais para a análise de imagens de plantas. De acordo com [Mohanty et al. 2016], técnicas baseadas em deep learning, especialmente CNNs, mostraram resultados promissores na identificação automática de doenças em folhas com alta acurácia. Modelos como VGGNet, ResNet, Inception e EfficientNet têm demonstrado sucesso notável em diversas aplicações, incluindo a detecção e classificação de doenças em folhas e outras partes de plantas, oferecendo uma abordagem automatizada e de alta precisão.

O dataset PlantVillage, é utilizado na comunidade de pesquisa em visão computacional, serve como base fundamental para o treinamento e a avaliação de modelos de classificação de doenças em plantas. [Hughes and Salathé 2015] introduziram o PlantVillage como um repositório público contendo várias imagens de folhas com doenças, com o intuito de apoiar a comunidade científica na criação de soluções automatizadas de detecção e diagnóstico. Contendo uma vasta coleção de imagens de folhas de diversas espécies, categorizadas entre plantas saudáveis e com diferentes tipos de doenças, ele proporciona um ambiente robusto para o desenvolvimento e teste de algoritmos. A diversidade das imagens neste dataset, que abrange variações de iluminação, ângulos e estágios de doença, permite o desenvolvimento de modelos com boa capacidade de generalização para cenários do mundo real. Tais estudos são fundamentais para que possam ser explorados os melhores modelos para cada cenário. A aplicação de técnicas de inteligência artificial para testagem e desenvolvimento de software tem se mostrado promissora [Sales 2020], assim como a utilização dessas técnicas em sistemas de manutenção baseada em condição [Simeón 2008]. Nem sempre um modelo se adequa a qualidade das imagens do conjunto de dados para treinamento e teste, por isso é importante comparar os resultados e aprimorar o seu aprendizado.

Este estudo tem como objetivo principal a implementação e comparação da eficiência de três arquiteturas distintas de CNNs: uma rede Densa (Fully Connected), a consolidada ResNet50 e um modelo híbrido de LSTM (Long Short-Term Memory) com CNN. A escolha dessas arquiteturas reflete a intenção de avaliar desde uma abordagem mais simples (Densa) até modelos pré-treinados e de maior complexidade (ResNet50) e, finalmente, uma arquitetura que pode ser relevante para cenários com sequências de imagens ou dados temporais (LSTM + CNN), embora o PlantVillage seja predominantemente de imagens estáticas, o que torna a inclusão da LSTM+CNN um ponto interessante para testar sua aplicabilidade ou para cenários futuros que envolvam vídeos ou sequências de dados. A comparação será realizada em termos de métricas de desempenho como acurácia, precisão, recall, F1-score e análise da matriz de confusão, além de considerar a eficiência computacional, como tempo de treinamento e inferência. [Tessele and Oliveira Junior 2024] destacam que a análise comparativa de diferentes arquiteturas é essencial, pois a acurácia geral pode mascarar erros graves, especialmente quando há classes semelhantes.

Ao final, espera-se não apenas fornecer uma análise comparativa aprofundada do desempenho dessas arquiteturas no contexto da classificação de doenças em plantas, mas também oferecer insights práticos para a seleção da arquitetura mais adequada para o desenvolvimento de sistemas de monitoramento agrícola eficientes e robustos. O entendimento dessas abordagens práticas fundamental para o desenvolvimento de sistemas de inteligência artificial em cursos de tecnologia, alinhando a formação acadêmica com as demandas do mercado e as tendências de IA [Vicari 2021].

2. METODOLOGIA / MATERIAIS E MÉTODOS

A metodologia deste estudo é centrada na implementação, treinamento e avaliação prática de diferentes arquiteturas de Redes Neurais Convolucionais (CNNs) para a classificação de doenças em plantas. O processo será dividido em três fases principais: Preparação dos Dados, Treinamento dos Modelos e Avaliação do Desempenho.

2.1. Preparação dos Dados

Para esta pesquisa, o conjunto de dados PlantVillage foi utilizado [Hughes and Salathé 2015], contendo imagens de folhas de diversas espécies, rotuladas quanto à presença e tipo de doença, ou status saudável. As etapas de preparação dos dados seguiram as boas práticas de aprendizado profundo, implementadas utilizando a biblioteca Keras no Python:

Carregamento e Redimensionamento das Imagens

As imagens do dataset foram carregadas e redimensionadas para um padrão de 224x224 pixels, utilizando `image_dataset_from_directory`. Esse tamanho é comumente utilizado e otimizado para as arquiteturas de CNN pré-treinadas.

Normalização

Os valores dos pixels das imagens foram normalizados para a faixa de [0, 1] automaticamente pelo pipeline de pré-processamento. Isso otimiza o processo de treinamento,

ajudando na convergência dos algoritmos de otimização.

Divisão dos Dados

O dataset foi dividido em conjuntos de treinamento, validação e teste nas proporções de aproximadamente 80%, 10% e 10%, respectivamente, configurados no `image_dataset_from_directory` para garantir a separação adequada para treinamento e avaliação.

Aumento de Dados (Data Augmentation)

Para aumentar a robustez e capacidade de generalização dos modelos, técnicas de aumento de dados foram aplicadas ao conjunto de treinamento. Isso foi realizado através da camada `RandomFlip("horizontal_and_vertical")`, `RandomRotation(0.2)`, `RandomZoom(0.2)`, `RandomContrast(0.2)` e `RandomTranslation(height_factor=0.2, width_factor=0.2)` do Keras. Esta etapa visou criar variações sintéticas das imagens originais e prevenir o overfitting.

2.2. Treinamento dos Modelos

Três arquiteturas de CNNs pré-treinadas foram implementadas e treinadas de forma comparativa, conforme especificado no notebook:

ResNet50

A arquitetura ResNet50 foi utilizada, carregada com pesos pré-treinados do ImageNet (`weights='imagenet'`). A camada de classificação original foi substituída por uma nova camada Dense com ativação softmax, adaptada para as 38 classes de doenças/estados saudáveis do PlantVillage. As camadas convolucionais pré-treinadas da ResNet50 foram congeladas para feature extraction, focando o treinamento apenas na nova camada de classificação, e em seguida, parte das camadas do backbone foi descongelada para fine-tuning de forma a ajustar melhor o modelo aos dados específicos.

VGG16

Similarmente, a arquitetura VGG16 foi carregada com pesos pré-treinados do ImageNet (`weights='imagenet'`). A camada de classificação foi removida e substituída por uma nova camada Dense para as 38 classes, seguida de uma ativação softmax. O backbone da VGG16 foi congelado para transferir o aprendizado, e posteriormente, uma parte foi descongelada para fine-tuning.

InceptionV3

A arquitetura InceptionV3 foi carregada com pesos pré-treinados do ImageNet (`weights='imagenet'`). Após a remoção da camada de classificação original, uma nova

camada `GlobalAveragePooling2D` foi adicionada, seguida de uma camada `Dense` para as 38 classes de saída com ativação `softmax`. As camadas convolucionais pré-treinadas da `InceptionV3` foram congeladas no início e então algumas camadas superiores foram descongeladas para permitir o `fine-tuning`.

O treinamento de cada modelo, realizado com apenas uma CPU Intel Core i5-10300H, incluiu a definição e ajuste de hiperparâmetros, como taxa de aprendizado, número de épocas e tamanho do lote.

O otimizador `tf.keras.optimizers.Adam` foi utilizado, e a função de perda `tf.keras.losses.CategoricalCrossentropy` foi selecionada, apropriada para problemas de classificação multiclasse. Callbacks como `EarlyStopping` (monitorando `val_loss` para interromper o treinamento quando a validação não melhora) e `ReduceLROnPlateau` (monitorando `val_loss` para reduzir a taxa de aprendizado quando o desempenho não melhora) foram utilizados para otimizar o processo de treinamento e evitar `overfitting`.

2.3. Avaliação do Desempenho

Após o treinamento, o desempenho de cada modelo foi rigorosamente avaliado usando o conjunto de dados de teste, que não foi visto durante o treinamento. As métricas de avaliação incluíram:

Acurácia

Medida geral de quão bem o modelo classifica as imagens corretamente.

Precisão (Precision)

A proporção de identificações positivas corretas (verdadeiros positivos) em relação ao total de identificações positivas (verdadeiros positivos + falsos positivos).

Recall (Sensibilidade)

A proporção de identificações positivas corretas (verdadeiros positivos) em relação ao total de casos positivos reais (verdadeiros positivos + falsos negativos).

F1-Score

A média harmônica da precisão e do recall, oferecendo um equilíbrio entre as duas.

Matriz de Confusão

Uma ferramenta visual que detalha o número de verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos para cada modelo, fornecendo uma visão granular de seu desempenho. As matrizes de confusão (absoluta e percentual) foram geradas e visualizadas usando `seaborn.heatmap`.

Além das métricas quantitativas, será realizada uma análise qualitativa das previsões dos modelos, identificando os tipos de erros e os desafios específicos enfrentados por cada arquitetura. A eficiência computacional será avaliada monitorando o tempo de treinamento e inferência em um ambiente controlado (CPU ou GPU, conforme disponível no ambiente de execução do notebook).

2.4. Análise Comparativa

Após a avaliação dos modelos, uma análise comparativa será realizada levando em consideração os seguintes critérios:

Desempenho de classificação

A acurácia, precisão, recall e F1-score serão comparados entre os modelos.

Eficiência computacional

O tempo de treinamento e inferência de cada modelo será medido para avaliar o uso de recursos computacionais, como memória e tempo de processamento.

Capacidade de generalização

Será comparado o desempenho de cada modelo no conjunto de validação e teste, a fim de verificar sua capacidade de generalizar para dados não vistos durante o treinamento.

3. Resultados

Esta seção apresenta os resultados obtidos com o treinamento e a avaliação dos três modelos de CNNs pré-treinadas: InceptionV3, ResNet50 e VGG16. O treinamento foi conduzido por 3 épocas para cada modelo, utilizando o dataset PlantVillage [Hughes and Salathé 2015], e os resultados são sumarizados a seguir, com gráficos de acurácia e perda (treinamento e validação) e matrizes de confusão detalhadas. A Figura 1 exibe, de forma comparativa, as curvas de acurácia e perda para os conjuntos de treinamento e validação dos três modelos ao longo das épocas. Essas curvas permitem visualizar a evolução do desempenho de cada rede durante o processo de aprendizagem, bem como identificar possíveis indícios de overfitting ou subajuste.

3.1. Desempenho do Modelo InceptionV3

O treinamento do modelo InceptionV3 demonstrou uma rápida convergência e alta performance. Os gráficos de acurácia e perda durante o treinamento e validação são apresentados na Figura 1. A acurácia final de validação para o InceptionV3 atingiu 0.8538, com uma perda de validação de 0.4623. Durante as épocas iniciais, observou-se uma acurácia de treinamento de aproximadamente 0.8832 e uma perda de 0.3754. O tempo de treinamento por época foi de aproximadamente 1500-1700 segundos. A matriz de confusão detalhada para o InceptionV3, que ilustra o desempenho do modelo em cada classe, é apresentada na Figura 2.




Figura 1. Curvas de Acurácia e Perda para o Modelo InceptionV3, ResNet50 e VGG16, Fonte: Autoria própria (2025).




Figura 2. Matriz de Confusão para o Modelo InceptionV3, Fonte: Autoria própria (2025).

3.2. Desempenho do Modelo ResNet50

O modelo ResNet50 também foi treinado e avaliado, com suas curvas de acurácia e perda durante o processo de treinamento e validação ilustradas na Figura1. A acurácia final de validação para o ResNet50 foi de 0.5650, com uma perda de validação de 1.5099. A acurácia de treinamento ao final das 3 épocas foi de aproximadamente 0.5629, e a perda de 1.5361. Este modelo apresentou um tempo de treinamento por época em torno de 2500-2600 segundos. A matriz de confusão correspondente ao desempenho do ResNet50 é exibida na Figura3.




Figura 3. Matriz de Confusão para o Modelo ResNet50, Autoria própria (2025).

3.3. Desempenho do Modelo VGG16

Os resultados do treinamento do modelo VGG16, incluindo as curvas de acurácia e perda para os conjuntos de treinamento e validação, são apresentados na Figura1.

O modelo VGG16 alcançou uma acurácia final de validação de 0.8809, com uma perda de validação de 0.3936. A acurácia de treinamento ao final das 3 épocas foi de aproximadamente 0.9130, e a perda de 0.3012. O tempo de treinamento por época foi significativamente maior, aproximadamente 5800 segundos. A matriz de confusão que detalha o desempenho de classificação do VGG16 é mostrada na Figura4.




Figura 4. Matriz de Confusão para o Modelo VGG16, Fonte: Autoria própria (2025).

3.4. DISCUSSÃO

A análise dos resultados obtidos com o treinamento e avaliação das arquiteturas ResNet50, VGG16 e InceptionV3 no dataset PlantVillage [Hughes and Salathé 2015] revela importantes insights sobre a eficácia CNNs pré-treinadas na classificação de doenças em plantas. Conforme demonstrado no gráfico de acurácia e perda (Figura 1) e nas matrizes de confusão (Figuras 2, 3 e 4) apresentados na seção de Resultados, todos os modelos alcançaram um desempenho notável, com acurácias de validação consistentemente elevadas.

Observando os resultados, a arquitetura VGG16 (Figura 4) demonstrou o maior valor de acurácia de validação final (0.8809) dentre os modelos treinados, indicando sua forte capacidade de aprendizado e generalização para o conjunto de dados. Contudo, esse desempenho veio acompanhado de um tempo de treinamento por época significativamente maior (aproximadamente 5800 segundos), o que é esperado dada a sua arquitetura com um grande número de parâmetros e camadas convolucionais densas.

A InceptionV3 (Figura 2) também exibiu um desempenho robusto, com uma acurácia de validação final de 0.8538. Embora ligeiramente inferior à VGG16 em acurácia, a InceptionV3 se destaca por sua eficiência computacional, apresentando um tempo de treinamento por época consideravelmente menor (aproximadamente 1500-1700 segundos). Isso se deve à sua arquitetura modular, que utiliza diferentes tamanhos de filtros em paralelo e emprega técnicas de redução de dimensionalidade para otimizar o uso de recursos, tornando-a uma opção atraente para cenários onde a velocidade de treinamento e inferência é crucial. A matriz de confusão da InceptionV3 revela uma alta precisão e recall para a maioria das classes, indicando sua eficácia na distinção entre diferentes condições de saúde das plantas, conforme observado por [Mohanty et al. 2016] em estudos similares.

Em contraste, o modelo ResNet50 (Figura 3) apresentou uma acurácia de validação final mais baixa (0.5650) em comparação com a VGG16 e a InceptionV3. Este resultado, juntamente com uma perda de validação mais alta (1.5099), sugere que a configuração de treinamento aplicada (apenas 3 épocas e fine-tuning talvez não tão extensivo) pode não ter sido suficiente para que o ResNet50, com sua complexidade de blocos residuais, explorasse todo o seu potencial neste dataset. A ResNet50 é conhecida por sua capacidade de treinar redes muito profundas e mitigar o problema do desaparecimento de gradientes, mas pode exigir mais épocas ou um ajuste mais fino dos hiperparâmetros e das camadas a serem descongeladas para superar as outras arquiteturas em cenários específicos. O tempo de treinamento por época (2500-2600 segundos) foi intermediário entre VGG16 e InceptionV3.

A alta acurácia alcançada pela VGG16 e InceptionV3, aliada à baixa incidência de falsos positivos e negativos observados em suas matrizes de confusão, indica o potencial dessas arquiteturas para serem integradas em sistemas de apoio à decisão para agricultores, como demonstrado por [Tessele and Oliveira Junior 2024] em aplicações similares com ML.NET. Um diagnóstico precoce e preciso de doenças pode diminuir as perdas na produção e otimizar os custos. A escolha da arquitetura ideal em uma aplicação prática dependerá de um equilíbrio entre o desempenho desejado e a eficiência computacional. Para implantações em dispositivos móveis ou sistemas embarcados em drones e equipamentos agrícolas, a InceptionV3 pode ser mais vantajosa devido ao seu tempo de

treinamento e inferência mais rápidos, mesmo que a VGG16 possa oferecer uma acurácia marginalmente superior.

Como limitações deste estudo, a dependência da qualidade e representatividade do dataset PlantVillage deve ser considerada; variações regionais de doenças, condições de iluminação extremas e diferentes estágios de desenvolvimento da planta podem não estar totalmente representados, o que pode impactar a generalização dos modelos para cenários do mundo real não vistos.

Para futuras pesquisas, sugere-se a exploração de outras arquiteturas de CNNs, como EfficientNet ou Vision Transformers (ViT), que têm demonstrado resultados positivos. A incorporação de técnicas de aumento de dados mais avançadas, pode enriquecer ainda mais o conjunto de treinamento. Finalmente, a validação dos modelos em datasets de campo, sob condições variadas, e a integração com sistemas embarcados para testes em tempo real.

Referências

- Garcia, A. C. (2020). Ética e inteligência artificial. *Revista da Sociedade Brasileira de Computação*. Acessado em: mar. 2025.
- Hughes, D. P. and Salathé, M. (2015). An open access repository of images on plant health to enable the development of mobile disease diagnostics. *arXiv preprint*. Acessado em: mar. 2025.
- Mohanty, S. P., Hughes, D. P., and Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7:1419. Acessado em: mar. 2025.
- Pinto, H. A. (2020). A utilização da inteligência artificial no processo de tomada de decisões: por uma necessária accountability. *Revista de Informação Legislativa: RIL*, 57(225):43–60. Acessado em: mar. 2025.
- Sales, J. L. (2020). Análise de modelo de aplicação com base em técnicas de inteligência artificial para testagem de software. Acessado em: mar. 2025.
- Simeón, E. J. A. (2008). Aplicação de técnicas de inteligência artificial no desenvolvimento de um sistema de manutenção baseada em condição. Dissertação (mestrado em sistemas mecatrônicos), Universidade de Brasília. Acessado em: mar. 2025.
- Tessele, V. and Oliveira Junior, M. B. d. (2024). Desenvolvimento de um modelo de detecção de doenças em soja com ml.net: Análise de performance. In *Congresso Latino-Americano de Software Livre e Tecnologias Abertas (LATINOWARE)*, pages 428–431, Foz do Iguaçu/PR. Sociedade Brasileira de Computação. Acessado em: mar. 2025.
- Tessele, V., Oliveira Junior, M. B. d., and Schulz, J. E. (2024). Treinamento de rede neurais artificiais para a identificação do momento de dessecação da soja. *Revista Caribeña De Ciencias Sociales*, 13(9):e4275. Acessado em: mar. 2025.
- Vicari, R. M. (2021). Influências das tecnologias da inteligência artificial no ensino. *Scielo*. Acessado em: mar. 2025.